

Análisis Predictivo del Mercado Inmobiliario

Regresión Lineal Múltiple - Airbnb

Universidad Tecmilenio

13 de mayo de 2026

1. Limpieza de Datos

Preparación del dataset para análisis

Proceso de Limpieza

1. **Imputación:** Valores faltantes con mediana (bathrooms, bedrooms, beds)
2. **Eliminación:** 14 columnas irrelevantes (IDs, URLs, fechas)
3. **Outliers:** Método IQR en beds, accommodates, log_price

Métrica	Original	Limpio
Filas	74,111	66,752
Columnas	29	14
Valores faltantes	83,752	0

Resultado

Dataset limpio: 66,752 observaciones × 14 variables

2. Identificación de Variables

Variable Dependiente (Y)

`log_price` — Logaritmo natural del precio de la propiedad

Variables Independientes Candidatas (X)

Numéricas / Binarias:

- ▶ `accommodates`, `bedrooms`, `bathrooms`, `beds`
- ▶ `amenities_count`, `cleaning_fee`, `instant_bookable`

Categorías:

- ▶ `room_type` (Entire home, Private room, Shared room)
- ▶ `property_type`, `bed_type`, `neighbourhood`
- ▶ `city`, `cancellation_policy`, `zipcode`

Total: 7 numéricas + 7 categóricas = 14 variables candidatas

3. Selección de Características

Análisis de multicolinealidad (VIF) y correlación

Variables EXCLUIDAS:

- ✗ beds
VIF = 14.89 (crítico)
- ✗ bathrooms, bedrooms
Colinealidad moderada y ruido
- ✗ zipcode
Redundante y de altísima cardinalidad


Variables INCLUIDAS:

- ✓ accommodates
Predictor principal
- ✓ amenities_count,
cleaning_fee,
instant_bookable
Nuevas variables añadidas
- ✓ room_type,
property_type,
bed_type, city,
cancellation_policy
Variables dummy relevantes
- ✓ neighbourhood
(609 variables dummy)

Total: ¿650 predictores


4. Análisis de Correlación

Pairplot y matriz de correlación




- ▶ **accommodates:** +0.522 (predictor principal)
- ▶ **bedrooms:** +0.293 (excluida por colinealidad)
- ▶ **bathrooms:** +0.155 (excluida por colinealidad)

5. Grupos de Entrenamiento y Prueba



Entrenamiento (80 %):

- 53,401 observaciones
- Media: 4.68
- Desv. Est.: 0.61



Prueba (20 %):

- 13,351 observaciones
- Media: 4.68
- Desv. Est.: 0.61

Random state: 42 (reproducibilidad)

6. Construcción y Entrenamiento del Modelo


Regresión Lineal Múltiple - Mínimos Cuadrados Ordinarios

Ecuación del Modelo

$$\log_price = \beta_0 + \beta_1 \cdot acc + \beta_2 \cdot amen + \beta_3 \cdot clean + \sum \text{dummies}$$

Top 25 Coeficientes del Modelo de Regresión Lineal Múltiple

Verde: Efecto positivo | Rojo: Efecto negativo



7. Evaluación del Modelo

Métricas de rendimiento

Métrica	Entrenamiento	Prueba
R^2	0.5993	0.5981
MSE	0.1481	0.1483
RMSE	0.3848	0.3851
MAE	0.2921	0.2926

Interpretación del R^2

El modelo explica el **59.81 %** de la variabilidad en log_price

Fortalezas:

- ✓ No sobreajuste
- ✓ Interpretable

Limitaciones:

- × 55 % varianza no explicada

8. Significancia Estadística (P-Values)

Validación matemática de las variables independientes

Prueba de Hipótesis

- ▶ **H₀**: La variable NO tiene efecto sobre el precio ($\beta = 0$)
- ▶ **H₁**: La variable SÍ tiene efecto sobre el precio ($\beta \neq 0$)
- ▶ **Umbral de confianza**: $\alpha = 0,05$ (Nivel del 95 %)

Resultados OLS (statsmodels):





- ▶ **Gran mayoría** de variables tienen $p < 0,05$ (Rechazamos H_0)
- ▶ Predictores base (accommodates, room_type) muestran $p \approx 0,000$

Conclusión de Significación

Las variables recién añadidas (city, cancellation_policy, instant_bookable) prueban ser **estadísticamente significativas** para la predicción de precios.

9. Predicciones

Comparación valores reales vs predicciones



10. Error Cuadrático Medio (MSE) y Conclusiones

MSE - Error Cuadrático Medio

- ▶ **MSE Entrenamiento:** 0.1481
- ▶ **MSE Prueba:** 0.1483
- ▶ **RMSE Prueba:** 0.3851 (error promedio en escala log)

Hallazgos Principales

1. **Predictor principal:** accommodates ($r = 0.52$)
 - ▶ Cada persona adicional aumenta precio $\sim 10\%$
2. **Ubicación (neighbourhood):** Factor crítico
 - ▶ 609 barrios con impactos variables en precio
 - ▶ Mejora R^2 de 44% a 60% ($+36\%$ explicación)
3. **Tipo de habitación:** También relevante
 - ▶ Private room: -46% vs Entire home
 - ▶ Shared room: -79% vs Entire home
4. **Nuevas variables integradas**
 - ▶ property_type y bed_type (categóricas)